Este notebook trata da importação do dataframe que servirá de base para os modelos de aprendizagem de máquina e está dividido da seguinte forma:

1 - Importa e processa dados do Secta (MERCADORIAS.csv)

2 - Analisa e processa coluna 'ncm'

3 - Cria funções auxiliares para o processamento da coluna descrição

4 - Analisa e processa coluna 'descricao'

5 - Cria a coluna 'descricao_limpa'

6 - Cria a coluna 'descricao_limpa_sem_stopwords'

7 - Cria a coluna 'descricao_limpa_stemming'

8 - Cria a coluna 'descricao_limpa_sem_stopwords_stemming'

In [1]:

```
import pickle
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
%matplotlib inline
import unicodedata
import re

import nltk
from nltk.stem import RSLPStemmer
import operator

from collections import Counter, defaultdict
from wordcloud import WordCloud

import sys
sys.path.append('..')
import extras.processtec as pt
```

1 - Importa e processa dados do Secta

In [2]:

```
secta = pd.read_csv('../data/MERCADORIAS.csv')
```

In [3]:

```
len(secta)  # tamanho do dataframe secta
```

Out[3]:

```
4467033
```

1.1 - Extrai informações do dataframe:

tamanho: 4.467.033

- colunas:

Data Registro, tipo de dado object

tipo, tipo de dado object

NCM, tipo de dado loat64

descrição, tipo de dado object

marca, tipo de dado object

modelo, tipo de dado object

Observacao, tipo de dado object

In [4]:

```
secta.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 4467033 entries, 0 to 4467032
Data columns (total 7 columns):
 #   Column         Dtype 
---  ------         ----- 
 0   Data Registro  object
 1   tipo           object
 2   NCM            float64
 3   descrição      object
 4   marca          object
 5   modelo         object
 6   Observacao     object
dtypes: float64(1), object(6)
memory usage: 238.6+ MB
```

In [5]:

```
secta.head(30)
```

Out[5]:

	Data Registro	tipo	NCM	descrição	marca	modelo	Observa
0	2010-01-06 00:00:00	ELETRONICOS	95041010.0	VIDEO GAME	MICROSOFT	XBOX 360	N
1	2010-01-06 00:00:00	ELETRONICOS	95041010.0	VIDEO GAME	SONY	PLAYSTATION 2	N
2	2010-01-06 00:00:00	ELETRONICOS	95041099.0	CONTROLE DE VIDEO GAME	SONY	PS2	N
3	2010-01-06 00:00:00	ELETRONICOS	95041099.0	CONTROLE DE VIDEO GAME	SONY	PS3	S/
4	2010-01-06 00:00:00	ELETRONICOS	95041099.0	ACESS DE VIDEO GAME	SONY	PS2	N
5	2010-01-06 00:00:00	ELETRONICOS	95041099.0	CONTROLE DE VIDEO GAME	NaN	NaN	N
6	2010-01-06 00:00:00	ELETRONICOS	95041099.0	CONTROLE DE VIDEO GAME	NINTENDO	WII	N
7	2010-01-06 00:00:00	ELETRONICOS	95041099.0	ACESS DE VIDEO GAME	NaN	NaN	N
8	2010-01-06 00:00:00	PERFUMES	33030010.0	PERFUME	NaN	NaN	N
9	2010-01-06 00:00:00	ELETRONICOS	95041099.0	MEMORY CARD P/VIDEO GAME	SONY	PSII	N
10	2010-01-06 00:00:00	OUTRAS	85122019.0	KIT DE LAMPADA XENON	NaN	NaN	N
11	2010-01-06 00:00:00	ELETRONICOS	95049090.0	VIDEO GAME MINIATURA	SONY	PSP 3000	N
12	2010-01-06 00:00:00	ELETRONICOS	95041010.0	VIDEO GAME	SONY	PLAYSTATION 3	N
13	2010-01-06 00:00:00	ELETRONICOS	85235110.0	MEMORIA FLASH P/MAQ.FOT.	NaN	2GB	N
14	2014-07-28 00:00:00	PERFUMES	33030010.0	PERFUME	ADIDAS	DYNAMIC - MASCULINO - 50 ML	N
15	2014-07-28 00:00:00	ELETRONICOS	85171891.0	TELEFONE	NaN	NaN	N

	Data Registro	tipo	NCM	descrição	marca	modelo	Observa
16	2014-07-28 00:00:00	ELETRONICOS	84703000.0	CALCULADORA DE MESA	SHARP	1801V	N
17	2014-07-28 00:00:00	ELETRONICOS	84703000.0	CALCULADORA DE MESA	SHARP	1750V	N
18	2014-07-28 00:00:00	ELETRONICOS	84703000.0	CALCULADORA DE MESA	CASIO	NaN	N
19	2014-07-28 00:00:00	ELETRONICOS	84701000.0	CALCULADORA	CASIO	CIENTÍFICA	N
20	2014-07-28 00:00:00	ELETRONICOS	85171211.0	WALK TALKIE	NaN	NaN	N
21	2014-07-28 00:00:00	ELETRONICOS	85183000.0	FONE DE OUVIDO	NaN	NaN	N
22	2014-07-28 00:00:00	ELETRONICOS	84703000.0	CALCULADORA DE MESA	CANON	5300	N
23	2014-07-28 00:00:00	ELETRONICOS	85171100.0	TELEFONE SEM FIO	NaN	NaN	N
24	2014-07-28 00:00:00	OUTRAS	38089999.0	AGROTOXICO	NaN	NaN	N
25	2014-07-28 00:00:00	ELETRONICOS	85044010.0	CARREGADOR DE PILHA	NaN	NaN	N
26	2014-07-28 00:00:00	ELETRONICOS	85271990.0	RADIO AM/FM	NaN	NaN	N
27	2014-07-28 00:00:00	OUTRAS	85232929.0	FITA DE FILMADORA	NaN	NaN	N
28	2014-07-28 00:00:00	OUTRAS	85078000.0	BATERIA DE TELEFONE S/FIO	NaN	NaN	N
29	2014-07-28 00:00:00	PNEUS	40111000.0	PNEU DE CAMIONETE	BCT	NaN	N

In [6]:

```
secta.describe()
```

Out[6]:

	NCM
count	4.467014e+06
mean	6.961921e+07
std	2.493719e+07
min	0.000000e+00
25%	4.201009e+07
50%	8.504401e+07
75%	8.527199e+07
max	1.000000e+08

Delimita o dataset para dados do ano 2021

In [7]:

```
secta = secta[secta['Data Registro'] > '2021-01-01 00:00:00']
```

In [8]:

```
len(secta)  # tamanho do dataframe secta
```

Out[8]:

```
174808
```

In [9]:

```
secta.head()
```

Out[9]:

	Data Registro	tipo	NCM	descrição	marca	modelo	Observacao
4103	2021-01-04 00:00:00	OUTRAS	85177099.0	ACESS DE CELULAR	NaN	NaN	NaN
4104	2021-01-04 00:00:00	PERFUMES	33030010.0	PERFUME	D HERMOSA	MARRY ME	100ML
4105	2021-01-04 00:00:00	PERFUMES	33030010.0	PERFUME	D HERMOSA	REMEMBER	100ML
4106	2021-01-04 00:00:00	PERFUMES	33030010.0	PERFUME	D HERMOSA	ROSE GOLD	100ML
4107	2021-01-04 00:00:00	OUTRAS	33049990.0	MAQUIAGEM	NaN	NaN	NaN

1.2 - renomeia colunas

In [10]:

```
# renomeia as colunas
secta = secta.rename(columns={"NCM": "ncm", "descrição": "desc", "Observacao": "observacao"
```

1.3 - exclui linhas com tipo e descrição vazias

In [11]:

```
sum(secta.desc.isna())
```

Out[11]:

```
0
```

In [12]:

```
secta = secta.dropna(subset=['desc'])
```

In [13]:

```
sum(secta.tipo.isna())
```

Out[13]:

```
0
```

In [14]:

```
secta = secta.dropna(subset=['tipo'])
```

1.4 - substitui a descrição genérica *[OUTROS (DEMAIS TIPOS)] por espaço vazio

In [15]:

```
# quantidade de termos '*[OUTROS (DEMAIS TIPOS)]' na coluna 'desc'
len(secta[secta['desc'] == '*[OUTROS (DEMAIS TIPOS)]'])
```

Out[15]:

```
4184
```

In [16]:

```
# substitui '*[OUTROS (DEMAIS TIPOS)]' por vazio e verifica quantidade
secta['desc'] = secta.desc.replace('*[OUTROS (DEMAIS TIPOS)]', '')
len(secta[secta['desc'] == '*[OUTROS (DEMAIS TIPOS)]'])
```

Out[16]:

```
0
```

1.5 - substitui o tipo genérico OUTRAS por espaço vazio

In [17]:

```
# quantidade de termos 'OUTRAS' na coluna 'tipo'
len(secta[secta['tipo'] == 'OUTRAS'])
```

Out[17]:

```
41721
```

In [18]:

```
# substitui 'OUTRAS' por vazio e verifica quantidade
secta['tipo'] = secta.tipo.replace('OUTRAS', '')
len(secta[secta['tipo'] == 'OUTRAS'])
```

Out[18]:

```
0
```

1.5 - Substitui valores NaN das colunas tipo, descrição, marca, modelo e Observacao

In [19]:

```
# substitui tudo que é NaN por vazio
secta['tipo'] = secta.tipo.replace(np.nan, '', regex=True)
```

In [20]:

```
secta['desc'] = secta.desc.replace(np.nan, '', regex=True)
```

In [21]:

```
secta['marca'] = secta.marca.replace(np.nan, '', regex=True)
```

In [22]:

```
secta['modelo'] = secta.modelo.replace(np.nan, '', regex=True)
```

In [23]:

```
secta['observacao'] = secta.observacao.replace(np.nan, '', regex=True)
```

In [24]:

```
secta.head(30)
```

Out[24]:

	Data Registro	tipo	ncm	desc	marca	modelo	ob
4103	2021-01-04 00:00:00		85177099.0	ACESS DE CELULAR			
4104	2021-01-04 00:00:00	PERFUMES	33030010.0	PERFUME	D HERMOSA	MARRY ME	
4105	2021-01-04 00:00:00	PERFUMES	33030010.0	PERFUME	D HERMOSA	REMEMBER	
4106	2021-01-04 00:00:00	PERFUMES	33030010.0	PERFUME	D HERMOSA	ROSE GOLD	
4107	2021-01-04 00:00:00		33049990.0	MAQUIAGEM			
4108	2021-01-04 00:00:00	BRINQUEDOS	95030099.0	BRINQUEDO			
4956	2021-01-04 00:00:00	INFORMATICA	85256090.0	ADAPTADOR USB P/REDE S/FIO	TP-LINK	ARCHER T4U	
4957	2021-01-04 00:00:00		95045000.0	ACESS DE VIDEO GAME	LOGITECH	X52 PRO	1750
4958	2021-01-04 00:00:00	INFORMATICA	85291019.0	ANTENA PARA INTERNET	UBIQUITI	LBE-M5-23	
4959	2021-01-04 00:00:00	BEBIDAS	22087000.0	LICOR	AMARULA	750ML	
4960	2021-01-04 00:00:00		33059000.0	TINTURA PARA CABELO			
4961	2021-01-04 00:00:00	BEBIDAS	22083020.0	UISQUE	JACK DANIELS	1L	
4962	2021-01-04 00:00:00	INFORMATICA	85176254.0	HUB	TP-LINK	TL-SG1024D	
4963	2021-01-04 00:00:00	RELOGIOS	91021900.0	RELOGIO DE PULSO			
4964	2021-01-04 00:00:00	ELETRONICOS	85272100.0	RADIO TOCA MP3 P/ AUTO			
4965	2021-01-04 00:00:00	INFORMATICA	85176259.0	UNIDADE DE REDE OTICA ONU			X

	Data Registro	tipo	ncm	desc	marca	modelo	ob
4966	2021-01-04 00:00:00	INFORMATICA	85176241.0	ROTEADOR P/REDE SEM FIO	TP-LINK	TL-WR849N	
4967	2021-01-04 00:00:00	VIDEOGAMES	95045000.0	CONTROLE DE VIDEO GAME	MICROSOFT	XBOX ONE	
4968	2021-01-04 00:00:00		85299020.0	ACESS DE TELEVISAO	XIAOMI	MI BOX S	
4969	2021-01-04 00:00:00	INFORMATICA	85176249.0	ROTEADOR	UBIQUITI	ROCKET AC	
4970	2021-01-04 00:00:00	ELETRONICOS	85235190.0	SSD (SOLID STATE DRIVE)	WD GREEN	240GB	
4971	2021-01-04 00:00:00	ELETRONICOS	85287190.0	RECEPTOR DE SATELITE	MYTV BOX		
4972	2021-01-04 00:00:00	ELETRONICOS	85176299.0	RECEPTOR DE MIDIA	GOOGLE	CHROMECAST	
4973	2021-01-04 00:00:00	INFORMATICA	85176241.0	REPETIDOR WIFI			
4974	2021-01-04 00:00:00		85299020.0	ACESS DE TELEVISAO	XIAOMI	MI TV STICK	
4975	2021-01-04 00:00:00		85101000.0	APARADOR DE BARBA	PANASONIC	ER389	
4976	2021-01-04 00:00:00	INFORMATICA	84733011.0	GABINETE	SATELLITE	8103K	
4977	2021-01-04 00:00:00		96035000.0	ESCOVA CABELO ELETRICA	QUANTA	QTES5900	
4978	2021-01-04 00:00:00	ELETRONICOS	85287190.0	RECEPTOR DE SATELITE			
4979	2021-01-04 00:00:00	PERFUMES	33030010.0	PERFUME	TED LAPIDUS	FANTASME 100ML	

1.5 - concatena as colunas 'desc', 'marca', 'modelo' e 'observacao' e cria nova coluna chamada 'descricao'

In [25]:

```
# cria nova coluna chamada 'descricao' cujo conteúdo é a concatenação
# das colunas 'desc', 'marca', 'modelo' e 'observacao'
secta['descricao'] = secta['tipo'] + ' ' + secta[
    'desc'].astype(str) + ' ' + secta['marca'].astype(str) +' '  + secta[
    'modelo'].astype(str) + ' '  + secta['observacao'].astype(str)
```

1.6 - cria um novo dataframe com as colunas 'descricao' e 'ncm'

In [26]:

```
# cria novo dataframe com as colunas 'descricao' e 'ncm'
secta = secta[['descricao','ncm']]
```

In [27]:

```
secta.head()
```

Out[27]:

	descricao	ncm
4103	ACESS DE CELULAR	85177099.0
4104	PERFUMES PERFUME D HERMOSA MARRY ME 100ML	33030010.0
4105	PERFUMES PERFUME D HERMOSA REMEMBER 100ML	33030010.0
4106	PERFUMES PERFUME D HERMOSA ROSE GOLD 100ML	33030010.0
4107	MAQUIAGEM	33049990.0

In [28]:

```
len(secta)
```

Out[28]:

```
174808
```

2 - Analisa e processa coluna "ncm"

2.1 - Análise de dados não numéricos e campos vazios. Tenta transformar valores em float, o que falhar transformar em 'NaN' para depois excluir

In [29]:

```
# tenta transformar em float, se não conseguir marca como NaN
for i, value in enumerate(secta.ncm):
    try:
        float(value)
    except Exception:
        secta.ncm[i] = float('NaN')
```

In [30]:

```
# quantidade de itens faltantes na coluna ncm
sum(secta.ncm.isna())
```

Out[30]:

```
8
```

In [31]:

```
# apaga todas as linhas do dataframe onde
# o valor da coluna ncm é valor faltante
secta = secta.dropna(subset=['ncm'])
```

In [32]:

```
# tamanho do dataframe após remoção
# dos valores faltantes
len(secta)
```

Out[32]:

```
174800
```

2.2 - Transforma valores em números inteiros, converte para string e preenche os zeros a esquerda de modo a termos 8 caracteres no total.

In [33]:

```
secta['ncm_str'] = secta.ncm.astype(float).astype(int).astype(str)
secta['ncm_str'] = secta.ncm_str.str.zfill(8)  # preenche zeros a esquerda de modo a termos
```

2.3 Cria colunas "capitulo", "posicao", "subposicao", "item" e "subitem" -

In [34]:

```
# os dois primeiros dígitos da NCM
secta['capitulo'] = secta.ncm_str.str[:2]
```

In [35]:

```
# terceiro e quarto dígitos da NCM
secta['posicao'] = secta.ncm_str.str[2:4]
```

In [36]:

```
# quinto e sexto dígito da NCM
secta['subposicao'] = secta.ncm_str.str[4:6]
```

In [37]:

```
# sétimo dígito da NCM
secta['item'] = secta.ncm_str.str[6]
```

In [38]:

```
# oitavo dígito da NCM
secta['subitem'] = secta.ncm_str.str[7]
```

In [39]:

```
# apaga se tiver capitulo '00' - no DF original havia uma linha de teste com esse valor
secta = secta.drop(secta[secta['capitulo'] == '00'].index)
```

In [40]:

```
len(secta)
```

Out[40]:

```
174793
```

2.4 - Análise estatística da coluna 'capítulo'.

2.4.1 Cria dicionário contendo o somatório total de cada capítulo

In [41]:

```
# cira dicionário com somatório total de itens na coluna
capitulos = {}
for value in secta.capitulo:
    if capitulos.get(value):
        capitulos[value] += 1
    else:
        capitulos[value] = 1
```

2.4.2 ordena do capítulos em ordem decrescente de quantidade

In [42]:

```
# ordena dicionário em ordem decrescente de quantidade
capitulos = dict(sorted(capitulos.items(), key=lambda item: item[1],reverse=True))
# exibe os 10 itens com mais registros
[(item,qtidd) for item, qtidd in capitulos.items() if qtidd > 2100]
```

Out[42]:

```
[('85', 74655),
 ('84', 20499),
 ('33', 16486),
 ('22', 12356),
 ('95', 8808),
 ('24', 5224),
 ('90', 4055),
 ('87', 3689),
 ('61', 3649),
 ('42', 2266)]
```

2.4.3 Gráfico de barras da quantidade de capítulos

In [43]:

```
# Cria gráfico de barras
values = secta['capitulo'].value_counts()  # conta quantidade de valores da coluna capítulo
threshold = 3000  # define limite inferior para exibição no gráfico (exibir 10 primeiros )
mask = values > threshold
values = values.loc[mask] # pega os valores que devem ser exibidos

# informações do gráfico
ax = values.plot(kind='bar', figsize=(14,8), title="Distribuição dos capitulos")
ax.set_xlabel("Capitulos")
ax.set_ylabel("Quantidade")
```

Out[43]:

```
Text(0, 0.5, 'Quantidade')
```

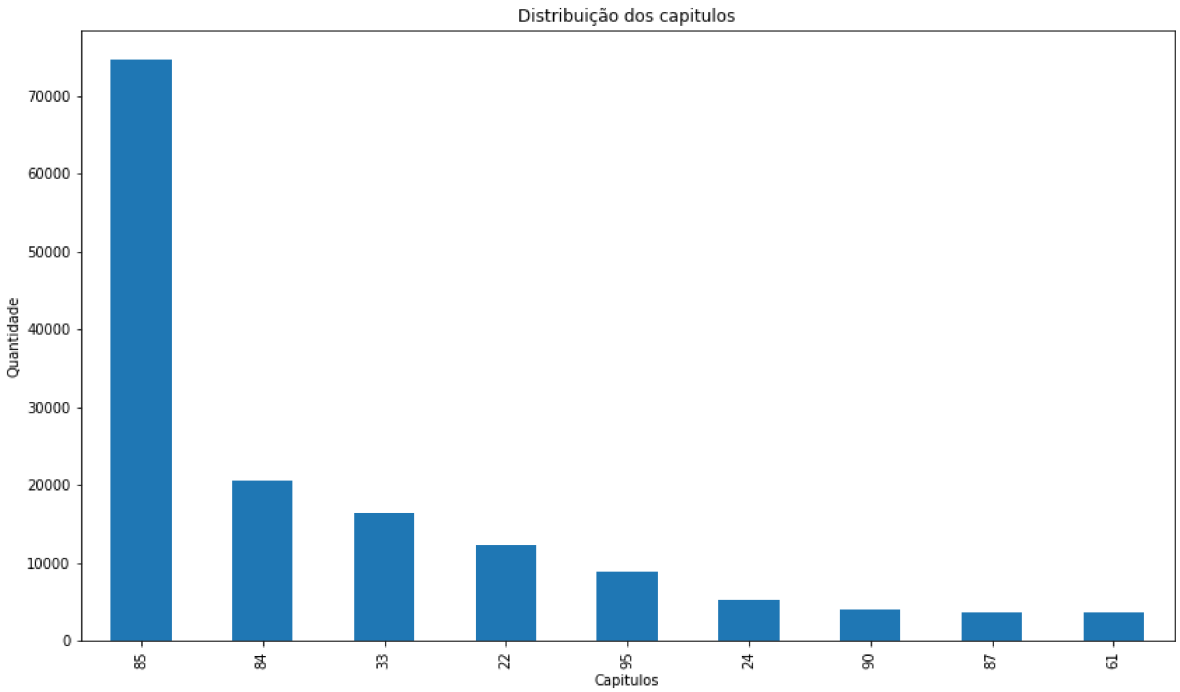

Conclusão - 'capitulo' com maior representatividade são:'85', '84', '33', '22', '95', '24', '90', '87', '61'

2.5 - Análise estatística da coluna 'posicao'.

In [44]:

```
# cira dicionário com somatório total de itens na coluna
posicao = {}
for value in secta.posicao:
    if posicao.get(value):
        posicao[value] += 1
    else:
        posicao[value] = 1

# ordena dicionário em ordem decrescente de quantidade
posicao = dict(sorted(posicao.items(), key=lambda item: item[1],reverse=True))
# exibe os 10 itens com mais registros
[(item,qtidd) for item, qtidd in posicao.items() if qtidd > 5100]
```

Out[44]:

```
[('17', 36314),
 ('04', 20938),
 ('03', 18479),
 ('71', 14402),
 ('18', 10076),
 ('02', 9821),
 ('23', 6502),
 ('28', 6076),
 ('07', 5727)]
```

In [45]:

```
# Cria gráfico de barras
values = secta['posicao'].value_counts()  # conta quantidade de valores da coluna capítulo
threshold = 5100  # define limite inferior para exibição no gráfico (exibir 10 primeiros )
mask = values > threshold
values = values.loc[mask] # pega os valores que devem ser exibidos

# informações do gráfico
ax = values.plot(kind='bar', figsize=(14,8), title="Distribuição das posições")
ax.set_xlabel("Posições")
ax.set_ylabel("Quantidade")
```

Out[45]:

```
Text(0, 0.5, 'Quantidade')
```

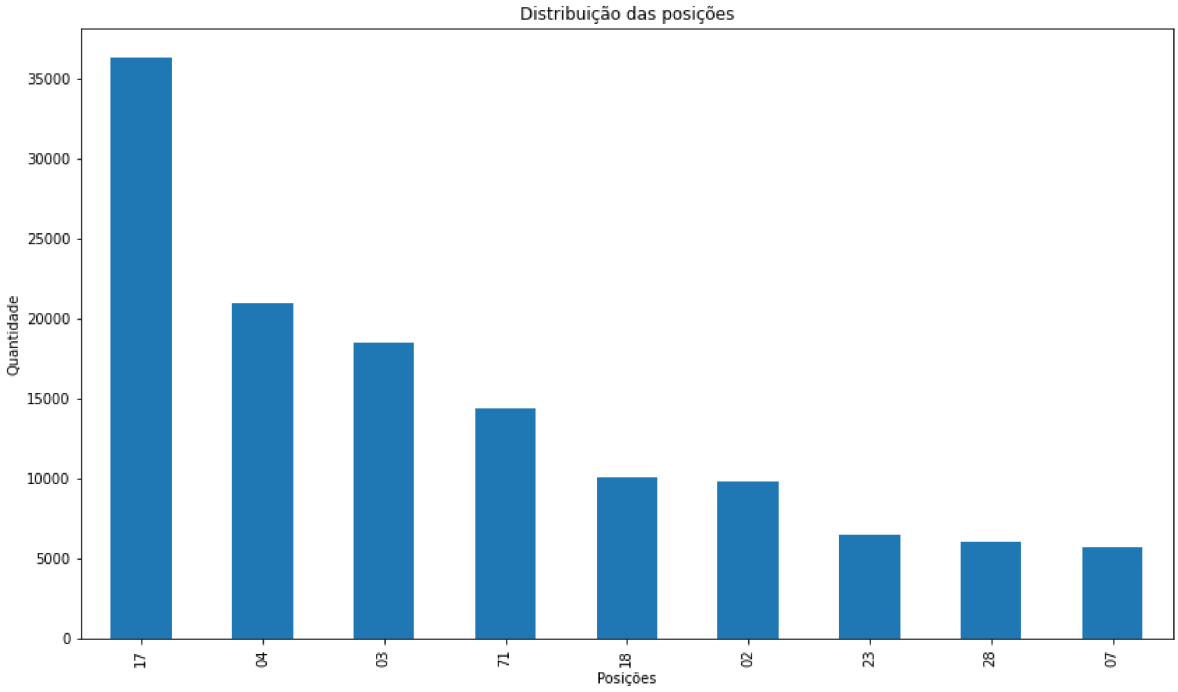

Conclusão - as posições com maiores frequências acumuladas são 17, 04, 03, 71, 18, 02, 23, 28, 07

2.6 - Análise estatística da coluna 'subposicao'.

In [46]:

```
# cira dicionário com somatório total de itens na coluna
subposicao = {}
for value in secta.subposicao:
    if subposicao.get(value):
        subposicao[value] += 1
    else:
        subposicao[value] = 1

# ordena dicionário em ordem decrescente de quantidade
subposicao = dict(sorted(subposicao.items(), key=lambda item: item[1],reverse=True))
# exibe os 10 itens com mais registros
[(item,qtidd) for item, qtidd in subposicao.items() if qtidd > 7100]
```

Out[46]:

```
[('12', 17865),
 ('00', 17041),
 ('90', 16873),
 ('62', 13966),
 ('30', 12833),
 ('21', 12567),
 ('41', 10077),
 ('10', 9313),
 ('70', 8356),
 ('20', 7888)]
```

In [47]:

```
values = secta['subposicao'].value_counts()
threshold = 7100
mask = values > threshold
values = values.loc[mask]

ax = values.plot(kind='bar', figsize=(14,8), title="Distribuição das subposições")
ax.set_xlabel("Subposições")
ax.set_ylabel("Quantidade")
```

Out[47]:

```
Text(0, 0.5, 'Quantidade')
```

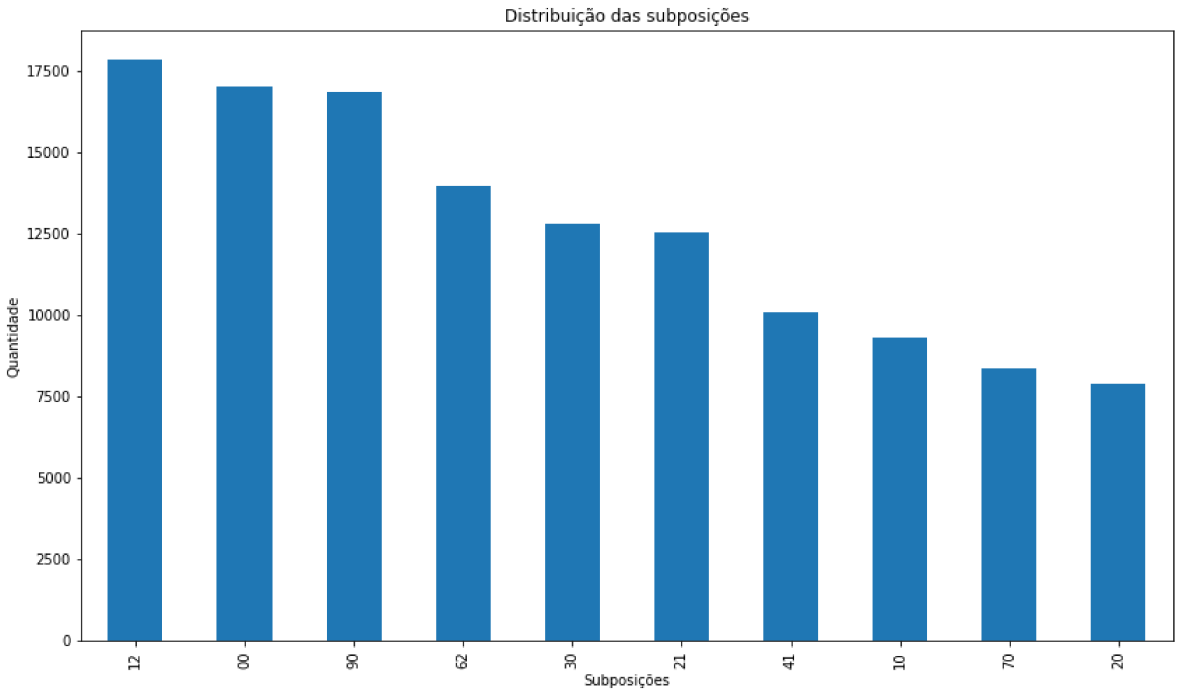

Conclusão - Os itens na coluna 'subposicao', os com maior representatividade (quantidade maior que 7100 itens) são: 12, 00, 90, 62, 30, 21, 41, 10, 70, 20

2.7 - Análise estatística das colunas 'item' e 'subitem'.

In [48]:

```
# Cria gráfico de barras
values = secta['item'].value_counts()  # conta quantidade de valores da coluna capítulo

# informações do gráfico
ax = values.plot(kind='bar', figsize=(14,8), title="Distribuição dos itens")
ax.set_xlabel("Itens")
ax.set_ylabel("Quantidade")
```

Out[48]:

```
Text(0, 0.5, 'Quantidade')
```

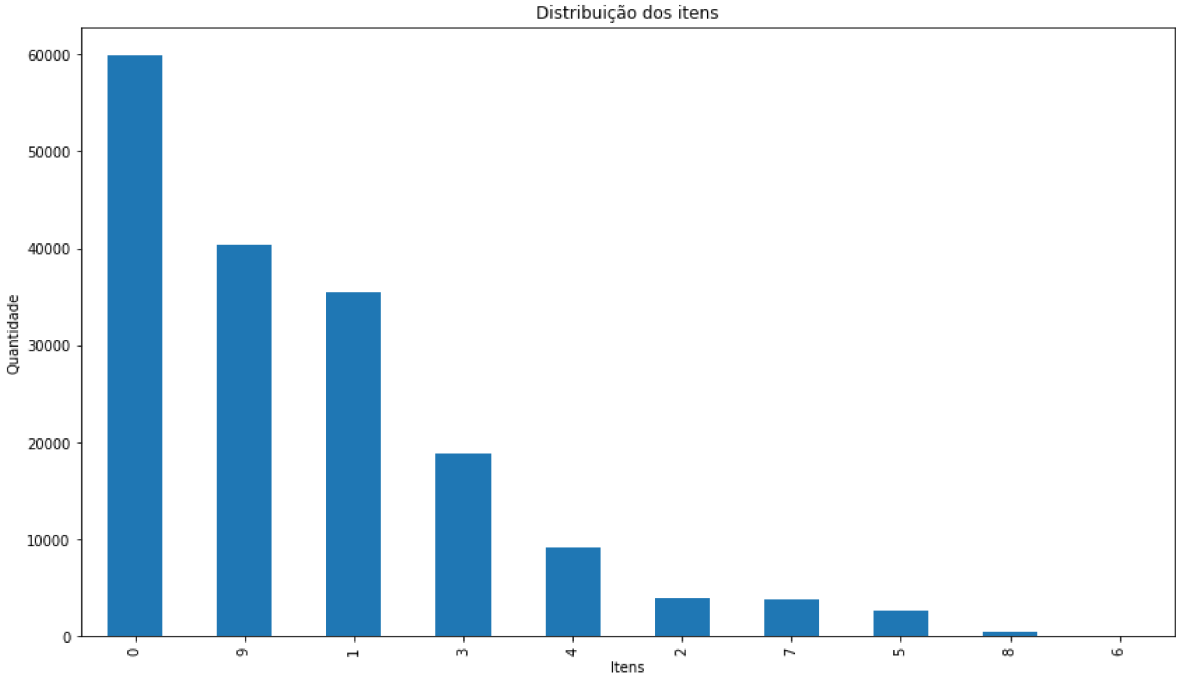

In [49]:

```
# Cria gráfico de barras
values = secta['subitem'].value_counts()  # conta quantidade de valores da coluna capítulo

ax = values.plot(kind='bar', figsize=(14,8), title="Distribuição dos Subitens")
ax.set_xlabel("Subitens")
ax.set_ylabel("Quantidade")
```

Out[49]:

```
Text(0, 0.5, 'Quantidade')
```

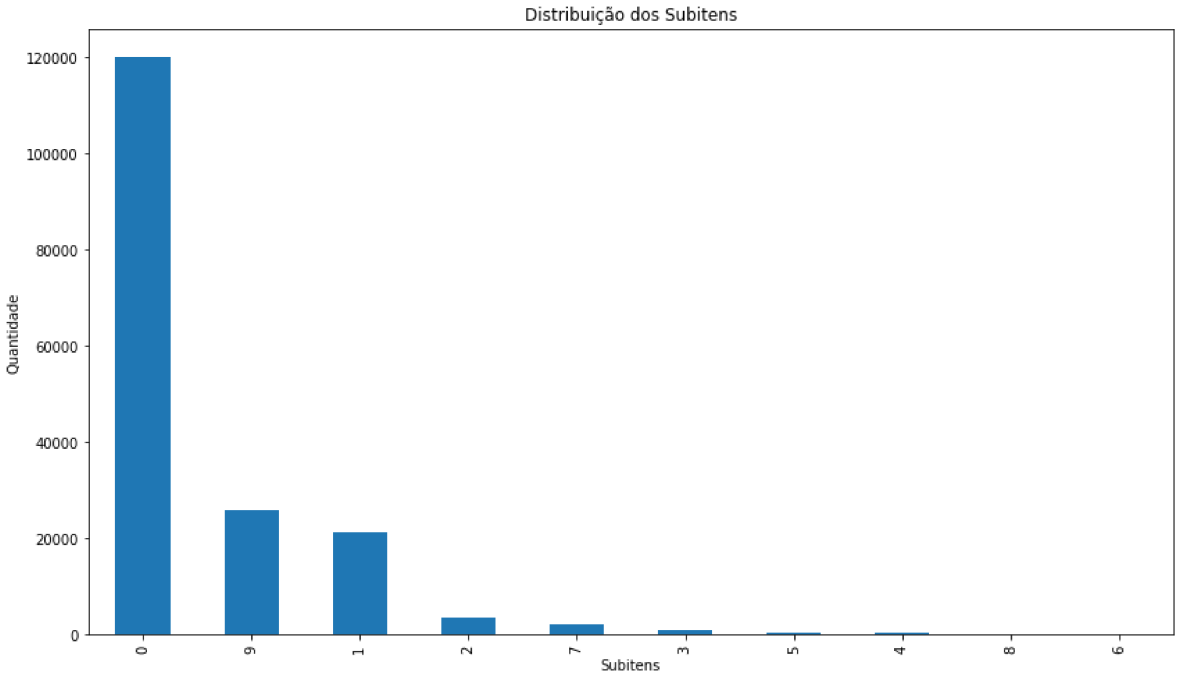

Conclusão: o dígito 0 é o que tem maior reprensentatividade tanto para item como para subitem

2.7 - Capítulos Faltantes:

In [50]:

```
print(f'O dataframe itens não contém o(s) capitlo(s):')
for i in range(96):
    if len(secta[secta['capitulo'] == str(i+1).zfill(2)]) == 0:
        print(f'{str(i+1).zfill(2)}', end=' ')
```

```
O dataframe itens não contém o(s) capitlo(s):
14 41 43 45 50 51 53 59 75 77 78 79 81
```

dataframe completo não contém os capítulos 43 53 75 77 81

dataframe de 2021 não contém os capítulos 14 41 43 45 50 51 53 59 75 77 78 79 81

3 - Cria funções que serão úteis para o processamento do texto do dataframe

3.1 - Função que remove sinais de pontuação e espaços

In [51]:

```
def remove_accents(input_str):
    """
    Função converte string em bytes, mas antes normaliza string usando NFKD

    NFKD - decompõem em dois code point e analisa compatibilidades (sem ser canonicamente e
    https://docs.python.org/3/library/unicodedata.html
    """
    nfkd_form = unicodedata.normalize('NFKD', input_str)
    only_ascii = nfkd_form.encode('ASCII', 'ignore')
    return only_ascii
```

3.2 - Função que retorna somente o radical da palavra passada como parâmetro

In [52]:

```
st = RSLPStemmer()
def stem_word(word):
    aux = word
    if aux != b'':
        aux = st.stem(aux.decode("utf-8"))  # pega o radical das palavras
        aux = str.encode(aux)
    return aux
```

3.3 - Função que verifica se é CPF ou CNPJ

In [53]:

```
def cpf_ou_cnpj(string):
    if re.search(
         "^([0-9]{2}[\.]?[0-9]{3}[\.]?[0-9]{3}[\/]?[0-9]{4}[-]?[0-9]{2})|([0-9]{3}[\.]?[0-9
         word):
        return True
    return False
```

3.4 - Função que processa o texto:

a) convertendo para minúsculo

b) removendo sinais de pontuação,

c) removendo sinais ortográficos,

d) remove CPF e CNPJ,

e) removendo stopwords (opcional),

f) retorna radicais das palavras - stemming (opcional)

In [54]:

```
def cria_coluna_descricao(dataframe, col_origem, col_destino, stop_words, stemming=False):
    num_words = Counter()
    word_count = Counter()
    times = 0
    novas_linhas = []
    col_index = dataframe.columns.get_loc(col_origem) + 1

    for linha in dataframe.itertuples():  # para cada linha do dataframe
        lista_linha = re.split('\W+', linha[col_index].strip())  # exclui sinais de pontuaç
        num_words[len(lista_linha)]+=1  # atualiza contador de quantidade de palavras
        nova_linha = []
        for word in lista_linha:
            word = word.lower()
            if word not in stop_words:  #verifica se não está nos stopword
                # verifica se não é CPF ou CNPJ
                 if not cpf_ou_cnpj(word):
                    word = remove_accents(word)  # remove acentuação
                    if stemming:
                        word = stem_word(word)  # retorna somente o radical da palavra
                    if word == b'no':
                        print(lista_linha)
                    word_count[word]+=1  # atualiza contador de palavras
                    nova_linha.append(word.decode().strip())
        if len(nova_linha) >= 0:
            novas_linhas.append(' '.join(nova_linha))

    dataframe[col_destino] = novas_linhas  # cria nova coluna do dataframe com as palavras
    return num_words, word_count
```

4 - Analisa e processa coluna 'descricao', que servirá para criação do vocabulário

4.1 - Criação da lista de palavras irrelevantes

Antes de criar vocabulários é necessário realizar análise das palavras irrelevantes.

Palavras irrelevantes são aquelas que descrevem a mercadoria num nível muito detalhado, incluindo por exemplo o nome da marca, o número de referência, etc.

Exemplo de descrição: 'telefone celular marca samsung', tanto a palavra 'marca' como 'samsung' são irrelevantes para classificação.

Dessa forma, iremos incluir na lista de stopwords (palavras que deverão ser eliminadas do dataframe) algumas palavras de referência (marca, ref, imitação) e a palavra seguinte a essa.

In [55]:

```
stop_words_posterior = set(['marca', 'ref', 'referencia', 'imitacao', 'modelo', 'nº',
                            'n', 'volume', 'tamanho', 'origem'])
aux = list(stop_words_posterior)
excecao = ['gabinete', 'bulbo', 'eletrico', 'inflavel', 'componentes',
           'diversas', 'diversos', 'digital', 'estatuetas', 'microfibra',
          'transparentes', 'headphone', 'bracelete', 'feminino']
```

In [56]:

```
for linha in secta['descricao']:
    linha = remove_accents(linha).decode()
    linha = linha.lower()
    for word in aux:
        if word in linha.split():  # garante que a stopword existe na linha
            posi = re.search(r'\b(' + word + r')\b', linha).start()
            if posi:
                try:
                    stop_word = linha[posi:].split()[1]  # pega a palavra posterior à palav
                    if not stop_word in excecao:
                        stop_words_posterior.add(stop_word)
                except IndexError:
                    pass
```

In [57]:

```
stop_words_anterior = set(['g', 'gramas', 'kg', 'kilos', 'kilograma',
                           'kilogramas', 'quilo','quilos', 'ml', 'l',
                           'litro', 'litros', 'mm', 'cm', 'm', 'giga',
                           'gigabyte', 'gigabytes', 'gb', 'tera', 'terabyte',
                           'terabytes', 'tb'])
aux = list(stop_words_anterior)
```

In [58]:

```
for linha in secta['descricao']:
    linha = remove_accents(linha).decode()
    linha = linha.lower()
    for word in aux:
        if word in linha.split(): # garante que a stopword existe na linha
            posi = re.search(r'\b(' + word + r')\b', linha).start()
            if posi:
                try:
                    stop_word = linha[:posi].split()[-1]  # pega a palavra anterior à palav
                    if not stop_word in excecao:
                        stop_words_anterior.add(stop_word)
                except IndexError:
                    pass
```

In [59]:

```
len(stop_words_posterior), len(stop_words_anterior)
```

Out[59]:

```
(1344, 500)
```

In [60]:

```
stop_words_itens = stop_words_posterior.union(stop_words_anterior)
len(stop_words_itens)
```

Out[60]:

```
1794
```

In [61]:

```
stop_words_outras = set(['brazil', '2020', '2019', 'parte', 'kit', 'xiaomi',
                         'huawei', '', '4gb', '32gb', '64gb', '128gb', '100ml', '750ml',
                         'no', '9', '8', 'c', 'imei', 'tp', 'link', 'redmi', 'hd'])
stop_words_itens = stop_words_itens.union(stop_words_outras)
len(stop_words_itens)
```

Out[61]:

```
1813
```

In [62]:

```
stop_words_posterior
```

Out[62]:

```
{'a144/',
 '8180',
 'nj-172',
 'mp-2218ase1',
 'ly-576',
 's6-v8-45w',
 'dow',
 '45w',
 'ac-1',
 '5041',
 'f8120-1100-d107',
 'centara',
 'yj1012',
 '6040',
 '69',
 'b-a54;',
 'ear7+',
 'vietna-cx1',
```

4.2 - Adicionar as palavras irrelevantes na lista de stopwords da biblioteca nltk

In [63]:

```
stopwords = nltk.corpus.stopwords.words('portuguese')
[stopwords.append(_) for _ in stop_words_itens]
stopwords = list(set(stopwords))  # apaga repetidas
print(len(stopwords))
```

```
2006
```

In [64]:

```
stopwords
```

Out[64]:

```
['',
 'a144/',
 'estejam',
 '8180',
 'nj-172',
 's6-v8-45w',
 'ly-576',
 'mp-2218ase1',
 'dow',
 '45w',
 'ac-1',
 '5041',
 'f8120-1100-d107',
 'joico',
 'houve',
 'centara',
 'yj1012',
 '6040',
```

5 - Cria a coluna 'descricao_limpa'

5.1 - Nessa coluna não foram retiradas as stopwords e também não foram retirados os afixos

In [65]:

```
# cria a coluna descricao_limpa sem informar nenhuma stopword e sem fazer o stemming
num_words, word_count = cria_coluna_descricao(secta, 'descricao', 'descricao_limpa', "")
```

```
['CIGARROS', 'CHARUTO', 'PARTAGAS', 'MADURO', 'NO', '1', 'CAIXA', 'COM',
'25', 'UNIDADES']
['CIGARROS', 'CHARUTO', 'PARTAGAS', 'SERIE', 'E', 'NO', '2', 'CAIXA', 'CO
M', '25', 'UNIDADES']
['CIGARROS', 'CHARUTO', 'HOYO', 'DE', 'MONTERREY', 'EPICURE', 'NO', '2',
'CAIXA', 'COM', '25', 'UNIDADES']
['INFORMATICA', 'PLACA', 'MAE', 'ASUS', 'PRIME', 'A320M', 'K', 'INSTALAD
A', 'NO', 'GABINETE']
['INFORMATICA', 'COOLER', 'VENTILADOR', 'CPU', 'AMD', 'INSTALADO', 'NO',
'GAINETE']
['PERFUMES', 'PERFUME', 'DREAM', 'BRAND', 'NO', '168', '25ML']
['PERFUMES', 'PERFUME', 'BRAND', 'COLLECTION', 'NO', '152', '25ML']
['PERFUMES', 'PERFUME', 'BRAND', 'COLLECTION', 'NO', '235', '25ML']
['PERFUMES', 'PERFUME', 'BRAND', 'COLLECTION', 'NO', '250', '25ML']
['CREME', 'PROD', 'BELEZA', 'DREAM', 'BRAND', 'NO', '194', '200ML']
['PERFUMES', 'PERFUME', 'BRAND', 'COLECTION', 'NO', '010', '25ML']
['BEBIDAS', 'UISQUE', 'JACK', 'DANIELS', 'OLD', 'Nº', '7', '1', 'LITRO']
['PERFUMES', 'PERFUME', 'BRAND', 'COLLECTION', 'NO', '003', '25ML']
['PERFUMES', 'PERFUME', 'DREAM', 'BRAND', 'COLLECTION', 'NO', '070', '25M
```

In [66]:

```
# itens.loc[8].descricao, itens.loc[8].descricao_limpa
```

In [67]:

```
# 20 palavras mais comuns (com maior freq acumulada)
word_count.most_common(20)
```

Out[67]:

```
[(b'de', 49719),
 (b'eletronicos', 31582),
 (b'telefones', 27452),
 (b'xiaomi', 27094),
 (b'informatica', 23422),
 (b'redmi', 19078),
 (b'celular', 17472),
 (b'smartphone', 16312),
 (b'note', 13307),
 (b'china', 12359),
 (b'bebidas', 12354),
 (b'origem', 11366),
 (b'telefone', 11318),
 (b'perfume', 11206),
 (b'perfumes', 11205),
 (b's', 10987),
 (b'64gb', 9854),
 (b'128gb', 9582),
 (b'vinho', 8989),
 (b'9', 7733)]
```

5.2 - Nuvem de palavras - 50 palavras mais frequentes

In [68]:

```
# cria um dicionário temporário 'text' com as 50 palavras mais frequentes
max_values = 50
text = {}
for (k, v) in word_count.most_common(max_values):
    text[str(k.decode())] = v
```

In [69]:

```
# cria a nuvem de palavras
wordcloud = WordCloud(width=1600, height=800).generate_from_frequencies(text)
```

In [70]:

```
# configurações de plotagem
fig, ax = plt.subplots(figsize=(20,10))
ax.imshow(wordcloud, interpolation='bilinear')
ax.set_axis_off()
plt.show()
```

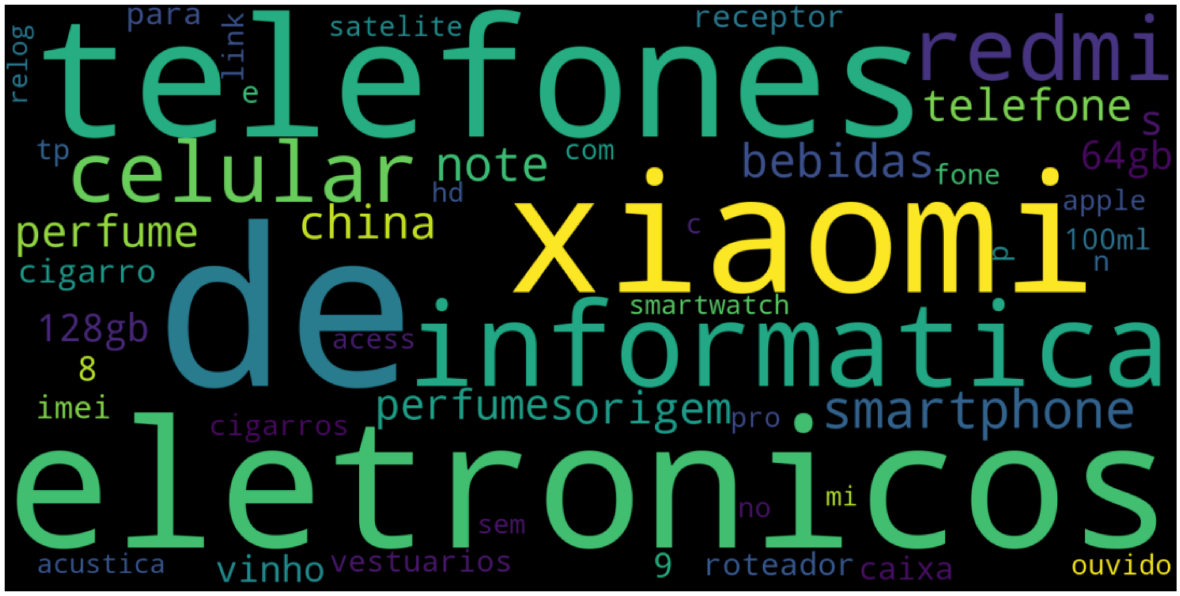

In [71]:

```
# Cria dataframe com as 50 palavras mais frequentes
df_word_count = pd.DataFrame()
df_word_count['descricao_limpa'] = text.keys()
df_word_count.head(10)
```

Out[71]:

	descricao_limpa
0	de
1	eletronicos
2	telefones
3	xiaomi
4	informatica
5	redmi
6	celular
7	smartphone
8	note
9	china

Conclusão: Pelo fato de não termos retirado as stopwords, dentre as palavras mais frequentes temos "de", "china", "origem" que são palavras que não agregam nada na classificação pois elas podem estar na descrição de diferentes NCMs

5.3 - Salva dataframe em formato parquet

In [72]:

```
secta.to_parquet('3_secta_desc_limpa.parquet')  # salva em formato parquet
```

6 - Cria a coluna 'descricao_limpa_sem_stopwords'

6.1 - Nessa coluna foram retiradas as stopwords para termos descrições com palavras mais importantes.

Não foram retirados os afixos

In [73]:

```
num_words, word_count = cria_coluna_descricao(secta, 'descricao', 'descricao_limpa_sem_stop
```

In [74]:

```
# itens.loc[8].descricao, itens.loc[8].descricao_limpa_sem_stopwords
```

In [75]:

```
word_count.most_common(20)
```

Out[75]:

```
[(b'telefones', 27452),
 (b'informatica', 23422),
 (b'celular', 17472),
 (b'smartphone', 16312),
 (b'bebidas', 12354),
 (b'telefone', 11318),
 (b'perfume', 11206),
 (b'perfumes', 11205),
 (b'vinho', 8989),
 (b'roteador', 6408),
 (b'receptor', 6361),
 (b'vestuarios', 5805),
 (b'cigarros', 5484),
 (b'fone', 4880),
 (b'pro', 4576),
 (b'acess', 4484),
 (b'satelite', 4374),
 (b'acustica', 4005),
 (b'smartwatch', 3954),
 (b'relog', 3848)]
```

6.2 - Nuvem de palavras - 50 palavras mais frequentes

In [76]:

```
max_values = 50
text = {}
for (k, v) in word_count.most_common(max_values):
    text[str(k.decode())] = v
```

In [77]:

```
wordcloud = WordCloud(width=1600, height=800).generate_from_frequencies(text)
```

In [78]:

```
fig, ax = plt.subplots(figsize=(20,10))
ax.imshow(wordcloud, interpolation='bilinear')
ax.set_axis_off()
plt.show()
```

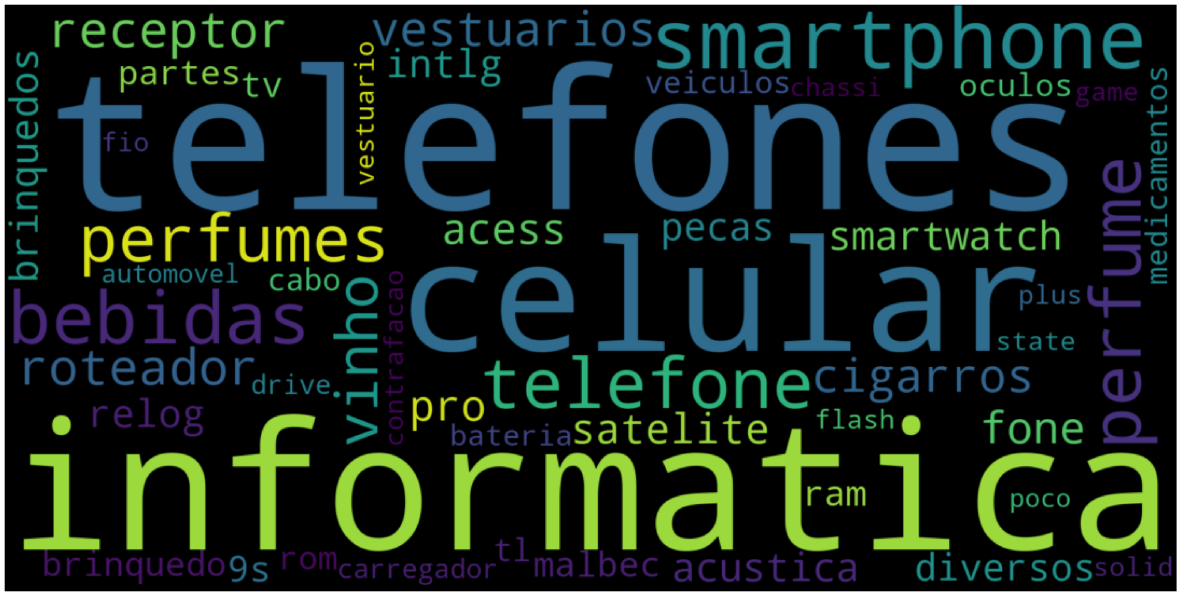

In [79]:

```
df_word_count['descricao_limpa_sem_stopwords'] = text.keys()
df_word_count.head(10)
```

Out[79]:

	descricao_limpa	descricao_limpa_sem_stopwords
0	de	telefones
1	eletronicos	informatica
2	telefones	celular
3	xiaomi	smartphone
4	informatica	bebidas
5	redmi	telefone
6	celular	perfume
7	smartphone	perfumes
8	note	vinho
9	china	roteador

Conclusão: a retirada de stopwords melhorou as palavras da descrição.

Vale a pena incluir no stopwords "china", "xiaomi", "huawei", "no", "gb"?

6.3 - Salva dataframe em formato parquet

In [80]:

```
secta.to_parquet('3_secta_desc_limpa_sem_stopwords.parquet')  # salva em formato parquet
```

7 - Cria a coluna 'descricao_limpa_stemming'

7.1 - Nessa coluna não foram retiradas as stopwords

Mas foram retirados os afixos, mantendo somente o radical das palavras

In [81]:

```
num_words, word_count = cria_coluna_descricao(secta, 'descricao', 'descricao_limpa_stemming
```

```
['CIGARROS', 'CHARUTO', 'PARTAGAS', 'MADURO', 'NO', '1', 'CAIXA', 'COM',
'25', 'UNIDADES']
['CIGARROS', 'CHARUTO', 'PARTAGAS', 'SERIE', 'E', 'NO', '2', 'CAIXA', 'CO
M', '25', 'UNIDADES']
['CIGARROS', 'CHARUTO', 'HOYO', 'DE', 'MONTERREY', 'EPICURE', 'NO', '2',
'CAIXA', 'COM', '25', 'UNIDADES']
['INFORMATICA', 'PLACA', 'MAE', 'ASUS', 'PRIME', 'A320M', 'K', 'INSTALAD
A', 'NO', 'GABINETE']
['INFORMATICA', 'COOLER', 'VENTILADOR', 'CPU', 'AMD', 'INSTALADO', 'NO',
'GAINETE']
['PERFUMES', 'PERFUME', 'DREAM', 'BRAND', 'NO', '168', '25ML']
['PERFUMES', 'PERFUME', 'BRAND', 'COLLECTION', 'NO', '152', '25ML']
['PERFUMES', 'PERFUME', 'BRAND', 'COLLECTION', 'NO', '235', '25ML']
['PERFUMES', 'PERFUME', 'BRAND', 'COLLECTION', 'NO', '250', '25ML']
['CREME', 'PROD', 'BELEZA', 'DREAM', 'BRAND', 'NO', '194', '200ML']
['PERFUMES', 'PERFUME', 'BRAND', 'COLECTION', 'NO', '010', '25ML']
['BEBIDAS', 'UISQUE', 'JACK', 'DANIELS', 'OLD', 'Nº', '7', '1', 'LITRO']
['PERFUMES', 'PERFUME', 'BRAND', 'COLLECTION', 'NO', '003', '25ML']
['PERFUMES', 'PERFUME', 'DREAM', 'BRAND', 'COLLECTION', 'NO', '070', '25M
```

In [82]:

```
# itens.loc[8].descricao, itens.loc[8].descricao_limpa_stemming
```

In [83]:

```
word_count.most_common(20)
```

Out[83]:

```
[(b'de', 49732),
 (b'telefon', 38773),
 (b'eletron', 34361),
 (b'xiaom', 27098),
 (b'informa', 23422),
 (b'perfum', 22427),
 (b'redm', 19080),
 (b'celul', 17507),
 (b'smartphon', 16322),
 (b'not', 13399),
 (b'beb', 13189),
 (b'cigarr', 12472),
 (b'chin', 12363),
 (b'orig', 11809),
 (b's', 10987),
 (b'64gb', 9854),
 (b'128gb', 9582),
 (b'vinh', 9010),
 (b'9', 7733),
 (b'vestuari', 7699)]
```

7.2 - Nuvem de palavras - 50 palavras mais frequentes

In [84]:

```
max_values = 50
text = {}
for (k, v) in word_count.most_common(max_values):
    text[str(k.decode())] = v
```

In [85]:

```
wordcloud = WordCloud(width=1600, height=800).generate_from_frequencies(text)
```

In [86]:

```
fig, ax = plt.subplots(figsize=(20,10))
ax.imshow(wordcloud, interpolation='bilinear')
ax.set_axis_off()
plt.show()
```

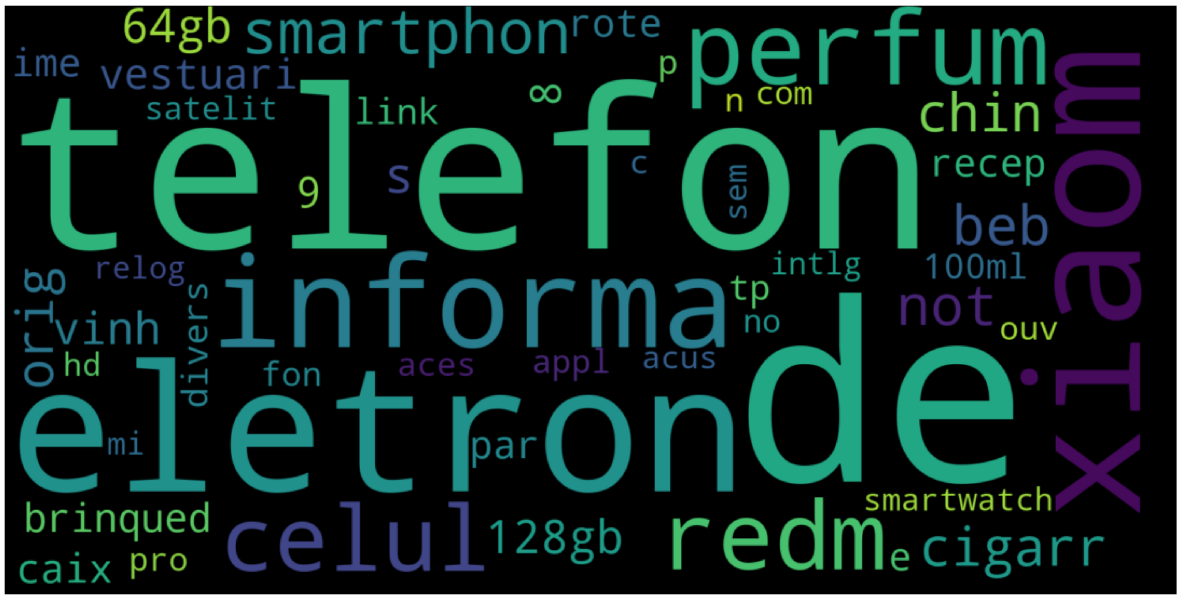

In [87]:

```
df_word_count['descricao_limpa_stemming'] = text.keys()
df_word_count.head(10)
```

Out[87]:

	descricao_limpa	descricao_limpa_sem_stopwords	descricao_limpa_stemming
0	de	telefones	de
1	eletronicos	informatica	telefon
2	telefones	celular	eletron
3	xiaomi	smartphone	xiaom
4	informatica	bebidas	informa
5	redmi	telefone	perfum
6	celular	perfume	redm
7	smartphone	perfumes	celul
8	note	vinho	smartphon
9	china	roteador	not

Conclusão: ainda há o problema das stopwords, mas com retirada dos afixos houve agrupamento de algumas palavras como 'feminino' e 'feminina', 'boneco' e 'boneca', 'diversos' e 'diversas', entre outras. Mas aparentemente não alterou as palavras mais frequentes.

obs: esse dataframe não será utilizado como dado de entrada do modelo

7.3 - Salva dataframe em formato parquet

In [88]:

```
secta.to_parquet('3_secta_desc_limpa_stemming.parquet')  # salva em formato parquet
```

8 - Cria a coluna 'descricao_limpa_sem_stopwords_stemming'

8.1 - Nessa coluna foram retiradas as stopwords e os afixos

In [89]:

```
num_words, word_count = cria_coluna_descricao(secta, 'descricao', 'descricao_limpa_sem_stop
```

In [90]:

```
# itens.loc[8].descricao, itens.loc[8].descricao_limpa_sem_stopwords_stemming
```

In [91]:

```
word_count.most_common(20)
```

Out[91]:

```
[(b'telefon', 38773),
 (b'informa', 23422),
 (b'perfum', 22427),
 (b'celul', 17507),
 (b'smartphon', 16322),
 (b'beb', 13189),
 (b'vinh', 9010),
 (b'vestuari', 7699),
 (b'brinqued', 6789),
 (b'rote', 6414),
 (b'recep', 6365),
 (b'cigarr', 5486),
 (b'divers', 5404),
 (b'fon', 4954),
 (b'pro', 4590),
 (b'aces', 4484),
 (b'satelit', 4378),
 (b'acus', 4012),
 (b'smartwatch', 3959),
 (b'relog', 3852)]
```

8.2 - Nuvem de palavras - 50 palavras mais frequentes

In [92]:

```
max_values = 50
text = {}
for (k, v) in word_count.most_common(max_values):
    text[str(k.decode())] = v
```

In [93]:

```
wordcloud = WordCloud(width=1600, height=800).generate_from_frequencies(text)
```

In [94]:

```
fig, ax = plt.subplots(figsize=(20,10))
ax.imshow(wordcloud, interpolation='bilinear')
ax.set_axis_off()
plt.show()
```

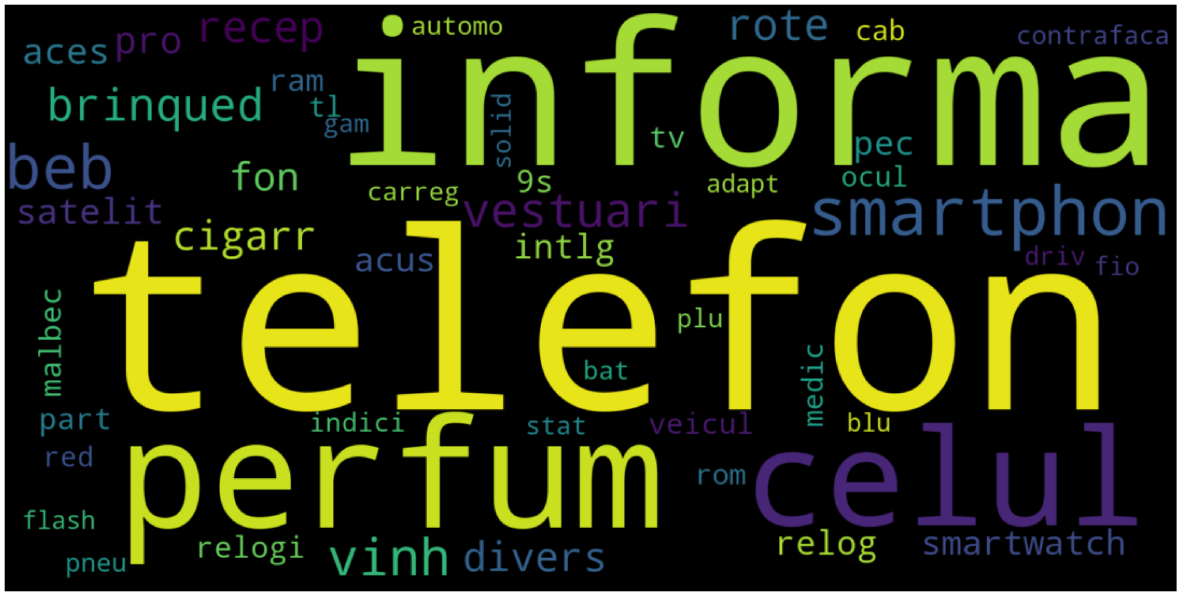

In [95]:

```
df_word_count['descricao_limpa_sem_stopwords_stemming'] = text.keys()
```

In [96]:

```
df_word_count = df_word_count.drop('descricao_limpa_stemming', 1)
```

In [97]:

```
df_word_count.head(20)
```

Out[97]:

	descricao_limpa	descricao_limpa_sem_stopwords	descricao_limpa_sem_stopwords_stemming
0	de	telefones	telefor
1	eletronicos	informatica	informa
2	telefones	celular	perfum
3	xiaomi	smartphone	celu
4	informatica	bebidas	smartphor
5	redmi	telefone	beb
6	celular	perfume	vinh
7	smartphone	perfumes	vestuar
8	note	vinho	brinquec
9	china	roteador	rote
10	bebidas	receptor	recep
11	origem	vestuarios	cigar
12	telefone	cigarros	divers
13	perfume	fone	for
14	perfumes	pro	pro
15	s	acess	aces
16	64gb	satelite	sateli
17	128gb	acustica	acus
18	vinho	smartwatch	smartwatch
19	9	relog	relog

Conclusão: retirando as stopwords podemos perceber uma diferença nas palavras mais relevantes. Contudo o fato de utilizar a técnica de stemming não surte muito efeito.

8.3 - Salva dataframe em formato parquet

In [98]:

```
secta.to_parquet('3_secta_desc_limpa_sem_stopwords_stemming.parquet')  # salva em formato p
```

In [ ]:

```

```

In [ ]:

```

```

In [ ]:

```

```

In [ ]:

```

```

In [ ]:

```

```